

Metoda największego spadku dla macierzy wstęgowej

Szymon Gwóźdź

21 marca 2024

1 Cel zajęć

Zadanie polega na rozwiązaniu układu równań liniowych $Ax = b$ metoda największego spadku.

2 Teoria

2.1 Macierz wstęgowa

Macierz wstęgowa, to taka macierz, której wszystkie elementy są zerowe poza diagonalą i wstega wokół niej.

$$a_{ij} \neq 0 \iff i - k_1 \leq j \leq i + k_2$$

, gdzie

$$k_{1,2} \geq 0$$

2.2 Metoda największego spadku

Metoda największego spadku (Gradient Descent) jest popularna metoda optymalizacji, wykorzystywana w wielu dziedzinach do znajdowania minimum funkcji kosztu lub błędu. W kontekście macierzy wstęgowej, ta metoda może być stosowana do rozwiązywania układów równań liniowych, gdzie macierz systemu jest macierzą wstęgową.

Metoda największego spadku dla macierzy wstęgowej skupia się na iteracyjnym zmniejszaniu wartości funkcji błędu (często kwadratowej sumy błędów) poprzez aktualizowanie rozwiązania w kierunku przeciwnym do gradientu funkcji kosztu. W kontekście układów równań liniowych $Ax = b$, gdzie A jest macierzą wstęgową, metoda ta polega na iteracyjnym poprawianiu przybliżonego rozwiązania x , aby zminimalizować residuum $r = b - Ax$.

3 Implementacja


1. Tworzenie macierzy wstęgowej (create matrix): Funkcja create matrix generuje macierz wstęgowa o rozmiarze $n \times n$, gdzie każdy element w "wstędze" o szerokości m od przekątnej jest zdefiniowany jako $1/(1 + |i - j|)$, a pozostałe elementy są zerami. To zapewnia, że macierz jest rzadka, ale ma charakterystyczne, nieliniarne elementy blisko przekątnej.
2. Metoda najszybszego spadku (fastest decline): Funkcja fastest decline realizuje iteracyjny proces znajdowania rozwiązania układu równań $Ax = b$, gdzie A to macierz wstęgowa, b to wektor prawych stron, a x to inicjalizacja wektora rozwiązań (początkowo zazwyczaj zerowy).
 - Residuum: Na początku każdej iteracji obliczane jest residuum r , czyli różnica między wektorem b a aktualnym przybliżeniem produktu Ax .
 - Krok iteracyjny: Następnie obliczana jest wartość α , reprezentująca długość kroku w kierunku gradientu residuum. Jest ona obliczana na podstawie wzoru $\alpha = \frac{r^T r}{r^T A r}$, co odpowiada minimalizacji kwadratu normy residuum wzdłuż kierunku spadku.
 - Aktualizacja rozwiązania: Rozwiązanie x jest aktualizowane poprzez dodanie do niego wektora kierunku pomnożonego przez długość kroku ($\alpha * r$).
 - Warunek zakończenia: Proces iteracyjny kontynuowany jest do momentu, gdy norma residuum spadnie poniżej zadanego progu dokładności (tutaj 10^{-6}).
3. Logowanie i wizualizacja: Kod zapisuje wartości norm residuum i rozwiązania do pliku data log.txt po każdej iteracji, co pozwala na późniejszą analizę konwergencji metody. Na koniec plik jest czytany, a zebrane dane są wykorzystywane do stworzenia wykresów zależności normy residuum i normy rozwiązania od numeru iteracji, co wizualnie przedstawia postęp metody.

4 Wyniki

Wygenerowany wykres przedstawia konwergencję metody najszybszego spadku poprzez zmiany normy residuum oraz normy rozwiązania w zależności od numeru iteracji.

- Norma residuum (pokazana na wykresie jako "Norma residuum") maleje eksponencjalnie z każdą iteracją, co sugeruje, że metoda najszybszego spadku efektywnie zmniejsza błąd między obliczonym a rzeczywistym rozwiązaniem układu równań liniowych. To pokazuje dobrą konwergencję metody.

- Norma rozwiązania (pokazana jako "Norma rozwiązania") zwiększa się logarytmicznie, co może reprezentować stopniowe zbliżanie się do faktycznego



rozwiązania układu równań. Zazwyczaj oczekivalibyśmy, że rozwiązanie będzie ewoluowało w kierunku rzeczywistego rozwiązania, co może być reprezentowane przez wzrost jego normy, zwłaszcza gdy początkowe przybliżenie jest dalekie od rozwiązania.

Wnioski płynące z tego wykresu są następujące:

1. Skuteczność metody: Malejąca norma residuum pokazuje, że metoda najszybszego spadku jest skutecznym narzędziem do minimalizacji błędów i znalezienia rozwiązania układu równań liniowych, szczególnie dla macierzy wstęgowej.

2. Konwergencja: Eksponencjalny spadek normy residuum wraz z kolejnymi iteracjami sugeruje szybką konwergencję metody, co jest pożądaną cechą w algorytmach optymalizacyjnych.

3. Ocena postępu: Wykres wskazuje na to, jak zmienia się błąd (norma residuum) i jak rozwija się rozwiązanie (norma rozwiązania) w zależności od liczby iteracji, co może być użyteczne do monitorowania postępu i decydowania o zatrzymaniu algorytmu, gdy osiągnięte zostaną zadowalające poziomy dokładności.

5 Podsumowanie

Podsumowując, analiza wykresu konwergencji metody najszybszego spadku dla rozwiązywania układów równań liniowych z macierzami wstęgowej wskazuje na kilka kluczowych aspektów. Po pierwsze, eksponencjalny spadek normy residuum w kolejnych iteracjach demonstruje skuteczność metody w szybkim zbliżaniu się do rozwiązania układu równań. Ta obserwacja podkreśla, że metoda najszybszego spadku jest wydajnym narzędziem optymalizacji dla problemów liniowych, zwłaszcza gdy stosowana jest do macierzy wstęgowych, które są często spotykane w zadaniach numerycznych związanych z równaniami różniczkowymi i różnicowymi.

Po drugie, logarytmiczny wzrost normy rozwiązania wskazuje na stopniową korektę przybliżonego rozwiązania w kierunku ostatecznego rozwiązania układu. Ta tendencja świadczy o tym, że metoda nie tylko zmniejsza błąd, ale także kieruje proces iteracyjny w stronę stabilnego i dokładnego rozwiązania.

Wreszcie, wykresy konwergencji, takie jak przedstawione, są nieocenionym narzędziem dla badaczy i inżynierów, umożliwiającym monitorowanie postępu algorytmów optymalizacyjnych i dokonywanie informowanych decyzji dotyczących ich zatrzymania na podstawie osiągniętej dokładności. W kontekście metody najszybszego spadku, szybka konwergencja i efektywne zbliżanie się do rozwiązania podkreślają jej wartość w rozwiązywaniu praktycznych problemów liniowych, szczególnie tych, które mogą być modelowane za pomocą macierzy wstęgowych.